## Démarche statistique Premiers pas avec R

#### **David Causeur** Agrocampus Ouest IRMAR CNRS UMR 6625

http://math.agrocampus-ouest.fr/infoglueDeliverLive/membres/david.causeur

#### Plan

- 1 Effet à l'échelle d'une population
- 2 Décider à partir de données
- Comparaison de groupes
  Analyse de variance à un facteur
  Estimation des paramètres d'effet
  Test de Fisher
  Le cas particulier de la comparaison de 2 groupes
  Décrire un effet groupe
  Test avec des données appariées
- 4 Effet linéaire

#### Plan

- 2 Décider à partir de données
- Analyse de variance à un facteur Test de Fisher

#### Plan

- Effet à l'échelle d'une population
- 2 Décider à partir de données
- 3 Effet 'groupe'

Comparaison de groupes
Analyse de variance à un facteur
Estimation des paramètres d'effet
Test de Fisher
Le cas particulier de la comparaison de 2 groupes
Décrire un effet groupe
Test avec des données appariées

4 Effet linéaire

## Comparaison de deux groupes

Test de l'effet d'un facteur à deux modalités :

$$\begin{cases} H_0: \ \delta = \mu_1 - \mu_2 = 0 \\ H_1: \ \delta = \mu_1 - \mu_2 \neq 0 \end{cases}$$

Test de comparaison entre sexes dans R

#### Test de Student

Reprenons la statistique de Fisher :

$$F = \frac{n_1(\overline{Y}_{1\bullet} - \overline{Y}_{\bullet\bullet})^2 + n_2(\overline{Y}_{2\bullet} - \overline{Y}_{\bullet\bullet})^2}{\hat{\sigma}^2}$$

avec

$$n_{1}(\overline{Y}_{1\bullet} - \overline{Y}_{\bullet\bullet})^{2} = n_{1}\left(\overline{Y}_{1\bullet} - \frac{n_{1}Y_{1\bullet} + n_{2}Y_{2\bullet}}{n_{1} + n_{2}}\right)^{2},$$

$$= n_{1}n_{2}^{2}\left(\frac{\overline{Y}_{2\bullet} - \overline{Y}_{1\bullet}}{n_{1} + n_{2}}\right)^{2},$$

$$n_{2}(\overline{Y}_{2\bullet} - \overline{Y}_{\bullet\bullet})^{2} = n_{2}n_{1}^{2}\left(\frac{\overline{Y}_{2\bullet} - \overline{Y}_{1\bullet}}{n_{1} + n_{2}}\right)^{2}.$$

Effet 'groupe'

#### Test de Student

#### Reprenons la statistique de Fisher :

$$F = \frac{n_{1}(\overline{Y}_{1\bullet} - \overline{Y}_{\bullet\bullet})^{2} + n_{2}(\overline{Y}_{2\bullet} - \overline{Y}_{\bullet\bullet})^{2}}{\hat{\sigma}^{2}}$$

$$= \left(\frac{\overline{Y}_{2\bullet} - \overline{Y}_{1\bullet}}{\hat{\sigma}}\right)^{2} \frac{n_{1}n_{2}(n_{1} + n_{2})}{(n_{1} + n_{2})^{2}},$$

$$= \left(\frac{\overline{Y}_{2\bullet} - \overline{Y}_{1\bullet}}{\hat{\sigma}\sqrt{\frac{1}{n_{1}} + \frac{1}{n_{2}}}}\right)^{2}.$$

#### Reprenons la statistique de Fisher :

$$F = T^2, \text{ où } T = \frac{\overline{Y}_{2\bullet} - \overline{Y}_{1\bullet}}{\hat{\sigma}\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} = \frac{\hat{\delta}}{\hat{\sigma}_{\hat{\delta}}}.$$

En effet,

$$\begin{split} \sigma_{\hat{\delta}}^2 &= \operatorname{Var}(\overline{Y}_{1\bullet} - \overline{Y}_{2\bullet}), \\ &= \operatorname{Var}(\overline{Y}_{1\bullet}) + \operatorname{Var}(\overline{Y}_{2\bullet}), \\ &= \sigma^2 \Big(\frac{1}{n_1} + \frac{1}{n_2}\Big). \end{split}$$

#### Test de Student

Reprenons la statistique de Fisher:

$$F = T^2, \text{ où } T = \frac{\overline{Y}_{2\bullet} - \overline{Y}_{1\bullet}}{\hat{\sigma}\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} = \frac{\hat{\delta}}{\hat{\sigma}_{\hat{\delta}}}.$$

Soit  $\hat{\theta}$  un estimateur de  $\theta$  et  $\hat{\sigma}_{\hat{\theta}}$  un estimateur de l'écarttype de  $\hat{\theta}$ .

Pour le test de H<sub>0</sub> :  $\theta = \theta_0$ ,  $T_{\theta_0} = (\hat{\theta} - \theta_0)/\hat{\sigma}_{\hat{\theta}}$  est appelée statistique de Student.

Effet 'groupe'

➤ Statistique du test de Student dans R

La distribution de T sous l'hypothèse nulle est la **loi de Student** à n-2 degrés de liberté, notée  $\mathcal{T}_{n-2}$ .

p-value du test de Student dans R

#### Test unilatéral

Test de  $H_0$ :  $\delta = 0$  contre  $H_1$ :  $\delta < 0$ .

Règle **unilatérale** de décision :  $H_0$  est rejetée si T prend une valeur jugée anormalement faible sous  $H_0$ .

lci, la p-value est la probabilité pour qu'une variable aléatoire de loi  $\mathcal{T}_{n-2}$  soit plus petite que la valeur observée de  $\mathcal{T}$ :

Test de Student unilatéral dans R

## Intervalle de confiance d'un paramètre

L'ensemble des valeurs  $\theta_0$  telles que  $H_0$ :  $\theta=\theta_0$  n'est pas rejetée au seuil  $\alpha$  est un intervalle de confiance de  $\theta$ , de niveau de confiance  $1-\alpha$ .

On en déduit l'intervalle de confiance  $\text{CI}_{1-\alpha}(\delta)$  :

$$\begin{aligned}
\mathsf{CI}_{1-\alpha}(\delta) &= \left\{ \delta_0, \ -t_{1-\alpha/2}^{(n-2)} \leq \frac{\hat{\delta} - \delta_0}{\hat{\sigma}_{\hat{\delta}}} \leq t_{1-\alpha/2}^{(n-2)} \right\}, \\
&= \left[ \hat{\delta} - t_{1-\alpha/2}^{(n-2)} \hat{\sigma}_{\hat{\delta}}; \hat{\delta} + t_{1-\alpha/2}^{(n-2)} \hat{\sigma}_{\hat{\delta}} \right].
\end{aligned}$$

Intervalle de confiance par t.test dans R

## Intervalle de confiance d'un paramètre

Pour les paramètres  $\mu_1$  et  $\mu_2$ :

$$\mathsf{CI}_{1-\alpha}(\mu_i) = \left[\hat{\mu}_i - t_{1-\alpha/2}^{(n-2)} \frac{\hat{\sigma}}{\sqrt{n_i}}; \hat{\mu}_i + t_{1-\alpha/2}^{(n-2)} \frac{\hat{\sigma}}{\sqrt{n_i}}\right].$$

Intervalle de confiance par t.test dans R

# Dans quelle mesure le test de Student peut-il détecter une différence de moyennes à l'échelle de la population?

Cas des données porcs : si la différence de moyenne entre mâles et femelles à l'échelle de la population vaut 1, le test de Student concluera-t'il que l'effet sexe est significatif?

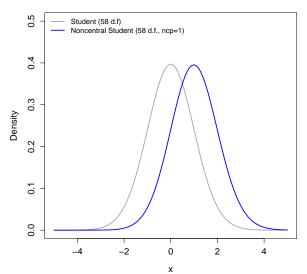
Soit le test de  $H_0$ :  $\mu_1 - \mu_2 = 0$  contre  $H_1$ :  $\mu_1 - \mu_2 = \delta \neq 0$ . Au seuil  $\alpha$ , la **puissance** du test est la probabilité sous  $H_1$  que le test rejette  $H_0$ :

Puissance(
$$\delta$$
) =  $\mathbb{P}_{\mu_1 - \mu_2 = \delta}(|T| \ge t_{1-\alpha/2}^{(n-2)})$ .

Sous  $H_1$ ,  $T \sim \mathcal{T}_{n-2}(\lambda)$  avec :

$$\lambda = \frac{\delta}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$
. [paramètre de non-centralité]

#### Density function of Student distribution (58 d.f.)



Plus  $\lambda$  est grand, plus le test de Student est puissant :

- Plus  $|\delta|/\sigma$  est grand, plus le test est puissant.
- Plus  $n_1$  et  $n_2$  sont grands, plus le test est puissant.

Puissance du test de Student dans R

#### **Tests Post-hoc**

L'effet d'un facteur est significatif = les moyennes de la variable réponse dans *certains* groupes sont différentes.

#### Quels groupes?

$$P_0 \neq P_{25} \neq P_{50}$$
 ou  $P_0 \neq \{P_{25} = P_{50}\}$  ou ...

#### Tests post-hoc pour 3 groupes : 3 tests simultanés

- $H_0^{(12)}$ :  $\mu_1 = \mu_2$ ,
- $H_0^{(13)}$ :  $\mu_1 = \mu_3$ ,
- $H_0^{(23)}$ :  $\mu_2 = \mu_3$ .
- Comparaisons deux à deux dans R

### Tests Post-hoc

#### Quel risque d'erreur pour plusieurs tests simultanés?

Probabilité d'au moins un rejet à tort (faux positif) :

$$\begin{split} &\mathbb{P}_{\mathsf{H}_0^{(ii')},\;i\neq i'}(\text{au moins une hypothèse }\mathsf{H}_0^{(ii')}\;\text{rejetée})\\ \leq &\;\;\sum_{i\neq i'}\mathbb{P}_{\mathsf{H}_0^{(ii')}}(\mathsf{H}_0^{(ii')}\;\text{rejetée}),\\ \leq &\;\;3\alpha \end{split}$$

#### Correction de Bonferroni : $\alpha^* = \alpha/3$ :

Correction de Bonferroni dans R

Effet 'groupe'

## Tests sur un paramètre - Résumé

- 1 Test de  $H_0$ :  $\theta = \theta_0$  contre  $H_1$ :  $\theta \neq \theta_0$  ou  $\theta > \theta_0$ 
  - Statistique du test de Student :  $T = (\hat{\theta} \theta_0)/\hat{\sigma}_{\hat{\theta}}$
  - Loi sous  $H_0$ :  $T \sim T_k$ , où k est le nombre de dégrés de liberté pour l'estimation de  $\hat{\sigma}_{\hat{a}}^2$
- 2 Intervalle de confiance de niveau  $1-\alpha$ : ensemble des  $\theta_0$  tels que  $H_0$  n'est pas rejetée au seuil  $\alpha$
- 3 Comparaison de moyennes :  $H_0$  :  $\mu_1 = \mu_2$
- 4 Evaluation d'un dispositif expérimental :
  - Puissance du test (à objectif de précision fixé)
  - Taille d'échantillon nécessaire (à objectifs de précision et de puissance fixés)
- 5 Tests post-hoc: correction du seuil (Bonferroni) pour un contrôle global du risque d'un faux positif.

Effet linéaire

- Analyse de variance à un facteur Test de Fisher
- Effet linéaire